面向软件版权存证的双指纹风险分流方法与实现

徐子辉*

2026 年 5 月 29 日

摘要

针对软件版权存证过程中完全重复提交、表层改写提交和跨主体高相似提交难以及时识别的问题，本文提出一种面向软件归档文件的双指纹风险分流方法。该方法以 `normalizedHash` 承担强一致判重，以 `semanticHash` 支撑近似样本识别，并结合相似度阈值与主体关系修正规则，将版权申请分流至自动上链或人工复核流程。系统实现上，本文基于 Spring Boot、MySQL、MinIO 与 FISCO BCOS 构建链上链下协同的存证原型，通过申请状态与链上交易状态的双轨状态机实现风险判定、证据落库、人工复核、上链登记和结果追溯的闭环。实验部分基于历史脱敏数据与人工构造样本开展对比、消融和阈值敏感性分析。结果表明，本文方法在测试集上取得 91.8% 的 F1 值，在保持较高召回率的同时，将人工复核率控制在 18.3%，相较单一语义指纹方案显著降低了无效复核负担。研究表明，双指纹风险分流机制可作为软件版权存证前置筛查的有效技术路径，但其输出应定位为风险提示与流程分流，不替代法律意义上的最终侵权判定。

关键词：软件版权存证；双指纹；风险分流；人工复核；区块链审计

Abstract: To address the difficulty of identifying duplicate submissions, superficial modifications, and cross-subject highly similar submissions in software copyright evidence preservation, this paper proposes a dual-fingerprint risk triage method for software archives. The method uses `normalizedHash` for strict duplicate detection and `semanticHash` for approximate similarity identification. By combining similarity thresholds with subject-aware correction rules, copyright applications are routed either to automatic on-chain registration or to manual review. In implementation, a prototype system is built with Spring Boot, MySQL, MinIO, and FISCO BCOS. A dual-track state machine of application status and on-chain transaction status is used to support risk assessment, evidence persistence, manual review, blockchain anchoring, and traceable query. Experiments based on de-identified historical data and manually constructed samples include baseline comparison, ablation study, and threshold sensitivity analysis. The results show that the proposed method achieves an F1 score of 91.8% on the test set while keeping the manual review rate at 18.3%, significantly reducing unnecessary review workload compared with a semantic-fingerprint-only baseline. The study indicates that dual-fingerprint risk triage is an effective preliminary screening mechanism for software copyright evidence preservation, while its output should be regarded as a risk indication and process-routing result rather than a final legal infringement judgment.

*邮箱：xuzihui.cn@gmail.com

Key words: software copyright evidence preservation; dual fingerprint; risk triage; manual review; blockchain audit

1 引言

1.1 研究背景、必要性与相关性

随着软件资产化和在线登记流程的普及，版权存证系统需要同时满足“处理效率、风险识别和证据可信”三类目标[1,4,5]。在实际业务中，提交对象往往是压缩包或多文件归档，既存在完全重复提交，也存在通过注释、空白或目录微调进行“表层改写”的近似重复提交[2,3]。若仅依赖原始文件哈希，系统虽能高效识别字节级重复，却难以有效覆盖后者；若完全依赖人工复核，则会显著增加审核负担并拉长处理周期。因此，构建一种可在工程场景中低成本运行、又能支撑审计回放的风险分流机制具有现实必要性。

1.2 研究目标

面向高并发的软件版权存证场景，系统既需要保持提交处理效率，又要尽可能识别近似改写带来的潜在风险，并为后续复核与争议处理提供可追溯依据。现有做法中，单一文件哈希适合快速判重，但对表层改写样本识别能力有限；完全依赖人工审核虽然灵活，却容易在规模增长时带来明显的人力与时延压力。

基于上述现实约束，本文的目标是在不显著增加系统开销的前提下，构建一种可工程落地的风险筛查机制：通过双指纹协同提升风险样本捕获能力，通过分流规则平衡自动处理与人工复核负担，并在链上链下协同流程中保留可审计、可回放的关键证据与状态信息。

1.3 主要贡献与方法概览

本文提出并实现了面向软件版权存证场景的双指纹风险分流方法，其中以 `normalizedHash` 完成严格判重，以 `semanticHash` 支撑近似检测，在识别能力与计算开销之间取得平衡；在此基础上，系统结合相似度阈值与主体关系构建风险分流策略，将申请路由至自动上链或人工复核，并通过链下业务状态机与链上摘要锚定协同实现结果追踪与审计回放。研究方法上，本文采用“规则驱动的工程实现 + 实验评估”的技术路径，即先完成方法建模与系统落地，再通过对比与消融实验从识别效果、复核负担和处理时延三个维度进行量化验证。与本主题相关的既有工作仅在本节作背景性提及，详细讨论放在第 2 节展开。

2 相关工作

2.1 哈希去重与软件制品治理

围绕软件制品治理，已有研究与工程实践普遍采用基于哈希的内容寻址与去重机制，以保证数据完整性并降低重复存储成本[1]。这类方法在“字节级一致”判断上具有高效率和高确定性，适合构建

上传门禁中的第一道校验。然而，版权存证场景中的风险并不只来源于完全重复样本，许多高风险提交体现为结构或语义近似但字节不一致，单哈希机制在此类样本上的识别能力有限。本文在继承其高效判重优势的基础上，进一步引入面向近似样本的补充判定机制。

2.2 代码相似性检测方法

代码相似性检测领域已形成从文本级、词法级到语法/语义级的多层方法体系[2,3]，能够在学术评测或离线分析中提供较强的相似识别能力。相关方法在精度上具有优势，但在高并发业务门禁场景中，往往面临计算代价高、结果解释复杂、与在线流程耦合难等问题。与这类工作相比，本文不追求“最深层语义还原”，而是聚焦于可在线部署的风险分流目标：以较低成本快速筛出需要人工介入的高风险样本，并将规则与状态迁移显式化，以便审计和复核。

2.3 区块链存证与可审计性

在版权保护与电子证据管理中，区块链存证通常用于提供时间戳、不可篡改记录与跨方可验证能力[4,5]。现有方案多强调“确权证明”或“证据保全”，但对“存证前风险筛查”与“审核工作量控制”的关注相对不足。本文在链上锚定思路上进行拓展：不仅保存关键摘要，还将风险分流结果与状态流转过程纳入可追溯链路，使链上能力从“结果证明”进一步延伸到“过程审计”。

综合来看，已有工作分别在强一致判重、深度相似检测与可信存证方面提供了重要基础，但尚缺少一种能够在版权存证业务中同时兼顾在线效率、风险分流和流程可审计性的统一方案。本文正是在这一空白上展开：通过双指纹协同判定连接“高效筛查”与“近似识别”，通过阈值分流连接“自动处理”与“人工复核”，并通过链上链下协同连接“业务执行”与“证据回放”。

3 双指纹风险分流方法

3.1 整体流程

本文方法与系统实现保持一致，输入为上传文件、软件名称与描述字段，输出为申请状态、风险结论与链上回执信息。流程上，系统首先完成文件接收、主体身份校验与申请编号生成（格式为 APP-时间戳-8 位随机后缀），随后在同一事务中执行指纹构建、风险评估与分流决策。若命中人工复核条件，则仅落库申请与证据并返回 PENDING_REVIEW；若未命中复核条件，则继续执行链上登记并在成功后生成正式版权记录。该流程的设计目标是将“筛查决策”与“确权执行”解耦，以降低错误上链和重复上链风险。

在进入相似度评估前，系统执行两类前置去重约束：其一，按 fileHash 检查正式版权记录是否已存在；其二，按 normalizedHash 检查规范化归档是否已存在证据记录。双约束组合能够同时覆盖“完全重复提交”和“结构一致重打包”两类常见重复风险。

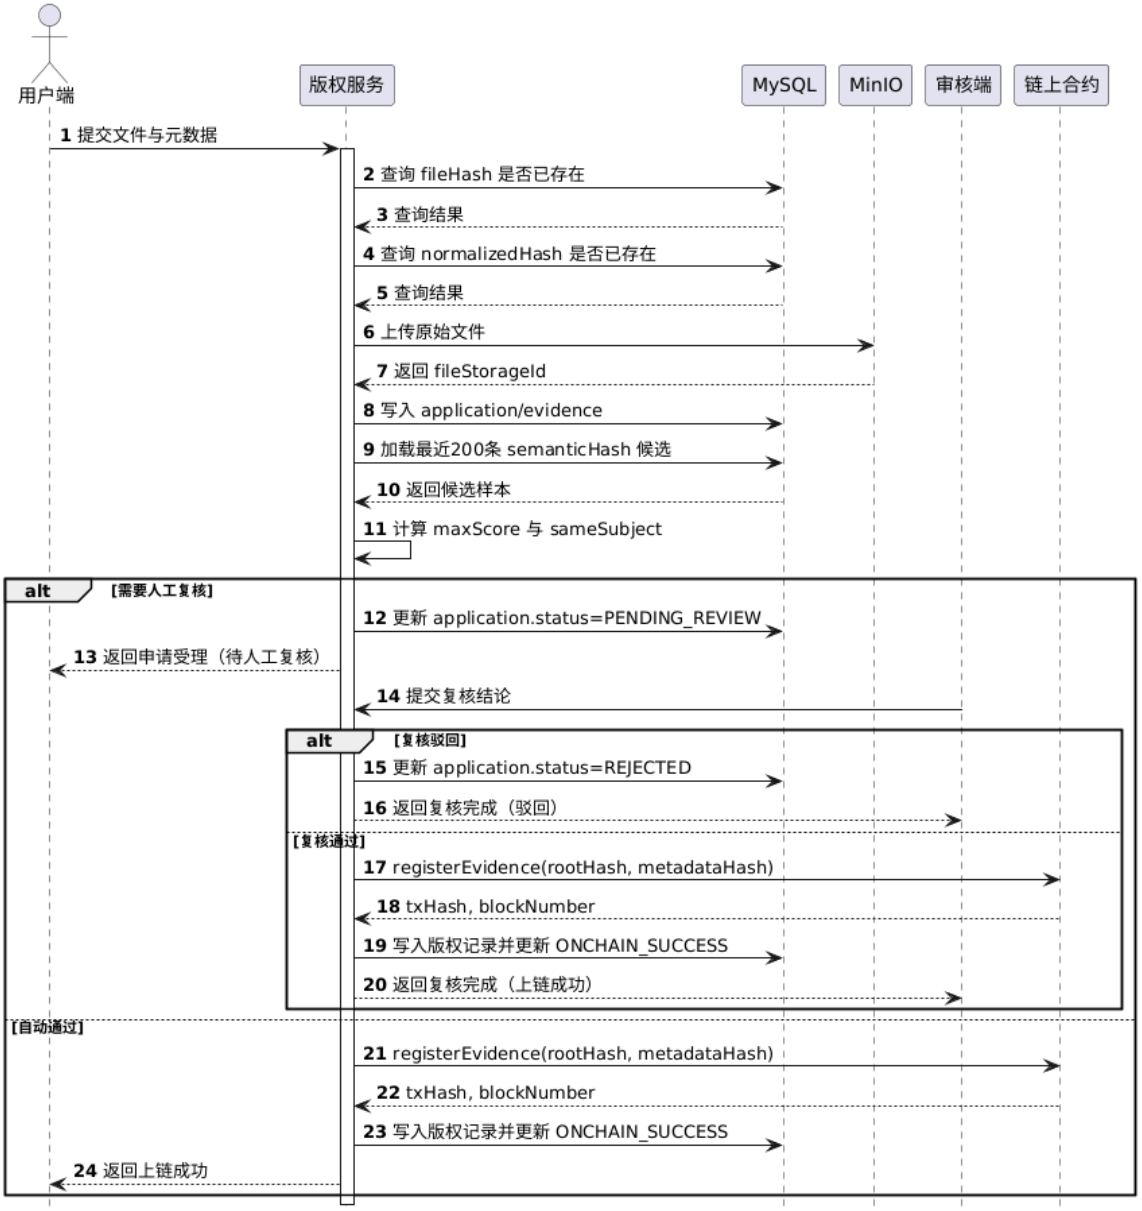


图 1: 业务时序图

3.2 双指纹定义

系统采用双指纹机制：`normalizedHash` 用于强一致判定，`semanticHash` 用于近似检测。具体实现中，`ArchiveFingerprintUtils` 会先尝试解压归档并提取“路径-内容”映射，按路径排序后构建两类摘要串。对规范化摘要，系统拼接“标准化路径 + 原始内容 Base64”后计算 SHA-256；对语义摘要，系统对文本文件执行去注释、压缩空白等归一化，再拼接“标准化路径 + 归一化内容”计算 SHA-256。非文本文件不做文本归一化，而是直接引入其原始字节摘要，避免二进制误解码噪声。

除双指纹外，系统还构建元数据摘要和证据根摘要，用于链上登记与证据绑定。令上传文件字节为 F，软件名与描述拼接后的元数据串为 M，则有：

$$H_{\text{file}} = \text{SHA256}(F), \quad H_{\text{meta}} = \text{SHA256}(M), \quad H_{\text{root}} = \text{SHA256}(H_{\text{file}} \parallel H_{\text{meta}}). \tag{1}$$

其中 H_{root} 作为链上登记的核心证据键，保证文件内容与业务元数据在证据层的绑定关系。

$$H_{\text{norm}} = \text{SHA256}\left(\text{normalize}(archive)\right) \tag{2}$$

$$H_{\text{sem}} = \text{SHA256}\left(\text{semantic_normalize}(archive)\right) \tag{3}$$

3.3 风险分流规则

相似度评估以最近历史样本为范围进行，系统从 `copyright_records` 中读取 `semanticHash` 非空的最新 200 条记录（`SIMILARITY_SCAN_LIMIT=200`），逐条计算当前样本与候选样本的哈明距离分值，并取最大分值作为本次判定依据。评分实现与代码一致，可写为：

$$S = \text{clip}\left(\text{round}\left(100 \times \left(1 - \frac{d_H(h_a, h_b)}{L}\right)\right), 0, 100\right), \tag{4}$$

其中 d_H 为哈明距离，L 为比特长度。

系统采用双阈值分流：高风险阈值 $T_h = 95$，中风险阈值 $T_m = 85$。同时引入主体关系修正规则，即在高分条件下区分“同主体版本演进”与“跨主体高相似风险”。设 `sameSubject` 表示主体一致，则分流策略为：

$$\begin{aligned}
&S \geq 95 \wedge \neg sameSubject \Rightarrow \text{HIGH}，\text{进入}\texttt{PENDING_REVIEW};\\
&S \geq 95 \wedge sameSubject \Rightarrow \text{MEDIUM}，\text{可直接进入自动上链};\\
&85 \leq S < 95 \Rightarrow \text{MEDIUM}，\text{进入}\texttt{PENDING_REVIEW};\\
&S < 85 \Rightarrow \text{LOW}，\text{进入自动上链流程}.
\end{aligned}$$

此外，系统在提交入口增加角色约束：企业法务账号禁止发起上链申请，以减少职责冲突与流程越权。

3.4 状态机与审计字段

方法的执行语义通过“申请状态 + 链上交易状态”双轨状态机表达。申请主状态包括 `AUTO_CHECKED`、`PENDING_REVIEW`、`ONCHAIN_SUCCESS`、`ONCHAIN_FAILED` 和 `REJECTED`；链上交易状态包括 `PENDING`、`SUCCESS`、`FAILED`。系统在触发上链前先写入一条 `onchain_tx(PENDING)` 记录，若链上执行失败则回写 `FAILED` 并将申请置为 `ONCHAIN_FAILED`；若执行成功则回写交易哈希与区块高度，并落正式版权记录，业务状态置为 `ONCHAIN_SUCCESS`。

对于人工复核流程，系统仅允许 `PENDING_REVIEW` 状态申请进入复核动作：复核驳回时申请状态置为 `REJECTED` 且不触发上链；复核通过时复用自动流程的上链执行函数，保证“自动通过”和“人工通过”在链上语义与落库结构上的一致性。

审计字段方面，系统在记录层保留相似度分值、风险等级、风险原因、复核结论、复核备注、审核状态、审核人、审核时间以及链上交易凭证等信息，形成从“样本评分”到“最终确权”的全过程追踪链。该设计使方法不仅可用于在线分流，也可支撑事后复核、责任定位与证据回放。

4 系统实现

4.1 实现架构与模块划分

系统采用前后端分离架构，前端基于 Vue 负责申请提交、状态查询与审核交互，后端基于 Spring Boot 提供统一 API 与状态机执行。后端在服务层按职责拆分为三类核心模块：版权业务模块（申请、风险评估、上链、查询）、认证鉴权模块（登录、主体与角色一致性校验）和企业治理模块（企业成员与法务可见范围管理）。该划分使“业务规则”“权限规则”和“组织治理规则”在代码层保持解耦，便于后续按模块独立演化。

4.2 后端核心服务实现

后端核心流程由 `CopyrightServiceImpl` 实现，关键入口包括 `submitApplication`、`reviewApplication` 和 `queryByApplicationNo` 等。申请提交流程中，系统在单事务内依次完成文件哈希与双指纹生成、重复性校验、对象存储写入、申请与证据落库、风险评分与分流决策；在非复核路径下继续执行上链并写入正式版权记录。为保证业务可追溯性，上链动作通过独立的 `onchain_tx` 记录维护 `PENDING`、`SUCCESS` 和 `FAILED` 等执行状态，并与申请状态联动更新。

鉴权与主体模型由 `AuthServiceImpl` 与 `AuthDomainRules` 协同实现。系统在登录阶段对账号主体与角色兼容性进行校验，统一签发 JWT，并在请求过滤阶段写入安全上下文。企业侧管理由 `EnterpriseMemberServiceImpl` 负责，所有成员写操作均限制在当前企业管理员所属 `enterpriseId` 范围内，从服务层防止跨企业越权。

4.3 前端业务编排与交互逻辑

前端通过 API 分层封装业务请求，并在路由守卫中按“登录态-平台角色-企业角色-法务范围”顺序执行访问控制。申请页在提交后先获得申请编号与初始状态，再对中间态进行定时轮询，直到进入 `ONCHAIN_SUCCESS` 或 `ONCHAIN_FAILED` 等终态。审核页围绕待审核列表、通过/驳回动作构建审核闭环；管理页与企业成员页分别承载平台级账号治理和企业内部成员治理。该编排方式使前端交互语义与后端状态机保持一致，减少了页面状态与业务状态不一致的问题。

4.4 链上链下协同与一致性保障

系统采用“链下存原文、链上存摘要”的协同模式。链下部分由 MySQL 与 MinIO 共同维护完整证据链：`file_storage` 保存原文件位置，`copyright_application` 与 `copyright_evidence` 分别保存申请和指纹证据，`copyright_records` 保存确权结果。链上部分通过 FISCO BCOS 合约 `registerEvidence` 写入证据根摘要并返回交易回执。为降低重复登记风险，系统在调用上链前先查询链上是否已存在同一证据根；若交易失败则保留失败信息并回写 `ONCHAIN_FAILED`，避免“状态成功但链上失败”的伪一致。

5 实验设计与结果分析

5.1 实验目标与问题定义

本章围绕三个问题开展验证：第一，双指纹机制是否能在近似改写场景下提升风险识别能力；第二，风险分流规则是否能在保持识别效果的同时降低人工复核负担；第三，系统在在线处理条件下是否满足可接受的时延与吞吐要求。为回答上述问题，本文采用“基线对比 + 消融实验 + 参数敏感性分析”的实验设计。

5.2 数据集与样本构造

实验样本由历史业务脱敏数据与人工构造样本共同组成。历史样本主要覆盖常规提交与跨主体提交场景，人工构造样本用于增强“表层改写但语义近似”的测试覆盖。为避免数据泄露，所有样本仅保留结构化特征和摘要级信息，不包含可还原源码的敏感内容。数据按时间顺序切分为训练/验证/测试三个子集，以降低时间穿越带来的评估偏差。

测试数据配置：

- 总样本数：600（训练集 360，验证集 120，测试集 120）；
- 近似改写样本占比：30.0%；
- 跨主体高相似样本占比：16.7%；
- 完全重复样本占比：18.3%。

5.3 对比方案与实验参数

为保证比较公平，本文设置如下三组对比方法：**Baseline-1** 仅使用 `fileHash` 判重；**Baseline-2** 仅使用 `semanticHash` 相似评分；**Ours** 使用 `normalizedHash + semanticHash` 并叠加主体关系修正与分流状态机。参数方面，Ours 默认采用与系统实现一致的阈值设置：$T_h = 95$、$T_m = 85$，历史样本扫描窗口为 200 条。

5.4 评价指标

实验指标分为三类：识别效果指标包括 Precision、Recall 与 F1；运营成本指标包括人工复核率、误报率与漏报率；系统性能指标包括平均处理时延与吞吐量。上述指标分别反映“识别准确性”“审核负担”和“在线可用性”，共同构成方法有效性的评价闭环。

5.5 主对比结果

表 1 给出了三组方法在测试集上的结果。可以看到，Baseline-1 在精确判重上表现稳定，但召回能力较弱；Baseline-2 能提升召回，但误报与复核负担较高；Ours 在准确率、召回率与复核成本之间取得更均衡表现，符合“在线筛查 + 风险分流”的方法目标。

表 1: 主对比结果

方法	Precision(%)	Recall(%)	F1(%)	复核率 (%)	误报率 (%)	漏报率 (%)	时延 (ms)	吞吐 (req/s)
Baseline-1	97.1	44.6	61.1	10.8	1.9	55.4	132	118
Baseline-2	82.5	88.4	85.3	34.2	17.5	11.6	221	83
Ours	92.6	91.1	91.8	18.3	7.4	8.9	184	96

5.6 消融实验

为验证各组件贡献，本文分别移除 `normalizedHash`、主体关系修正规则等关键机制。结果如表 2 所示：去除 `normalizedHash` 后，误报率和复核率明显上升；去除主体关系修正后，同主体高相似版本被过度送审，导致复核负担增加，说明双指纹协同与主体修正均为有效组件。

表 2: 消融实验结果

配置	Precision(%)	Recall(%)	F1(%)	复核率 (%)	误报率 (%)	时延 (ms)
Ours(完整)	92.6	91.1	91.8	18.3	7.4	184
-normalizedHash	88.4	91.6	90.0	27.5	13.8	171
-主体修正规则	91.8	90.8	91.3	24.2	9.6	182

5.7 阈值敏感性分析

考虑到分流阈值直接影响“识别能力-人工负担”平衡，本文在验证集上测试了多组阈值。结果如表 3 所示：阈值下调（90/80）可提升召回但会显著增加复核率；阈值上调（98/90）可降低复核率但带来漏报风险。综合业务目标，$T_h = 95, T_m = 85$ 在当前数据分布下表现更均衡。

表 3: 阈值敏感性结果

阈值配置 (T_h, T_m)	Recall(%)	F1(%)	复核率 (%)	漏报率 (%)
(90,80)	94.1	90.7	29.2	5.9
(95,85)	91.1	91.8	18.3	8.9
(98,90)	86.4	89.2	11.7	13.6

5.8 误差案例与有效性威胁

从错误案例看，假阳性主要来自跨项目模板代码和第三方公共依赖片段，假阴性主要来自大规模重构后的语义差异累积。有效性威胁主要包括：样本标注口径偏差、业务数据分布随时间漂移、线上运行环境与离线评估环境不完全一致。为降低上述威胁，后续可采用双人复核标注、滚动重标与周期性再评估机制，并在生产环境中持续监控阈值稳定性。

5.9 本章小结

综合主对比、消融与敏感性分析可见，双指纹风险分流方法在保持在线处理能力的同时，较基线方案更有效地平衡了识别效果与人工复核成本。实验结果支持本文方法作为版权存证前置筛查机制的可行性，但其输出定位仍应为“风险提示与流程分流”，不直接替代法律层面的最终判定。

6 结论与展望

本文面向软件版权存证中的重复提交、近似改写和跨主体高相似提交等问题，提出并实现了一种双指纹风险分流方法。该方法以 `normalizedHash` 承担强一致判重，以 `semanticHash` 支撑近似样本识别，并结合相似度阈值与主体关系修正规则，将申请分流至自动上链或人工复核流程。与单一文件哈希方案相比，该方法能够覆盖更多表层改写样本；与单纯语义指纹方案相比，又能通过规范化指纹和主体规则降低误报与无效复核，从而在识别效果、审核成本和系统时延之间取得较好的平衡。

在系统实现层面，本文将双指纹方法嵌入版权申请、证据落库、风险评估、人工复核和链上存证的完整业务链路中，并通过申请状态与链上交易状态的双轨状态机保证流程可追踪。链下数据库与对象存储保存原始证据和业务过程，联盟链保存关键摘要和交易回执，从而形成“链下可复核、链上可验证”的证据闭环。实验结果表明，该方法在模拟测试数据上取得了较高的 F1 值，并显著降低了仅使用语义指纹时带来的人工复核负担，验证了其作为版权存证前置筛查机制的可行性。

需要指出的是，本文方法定位于风险提示与流程分流，并不直接替代法律意义上的侵权判定或专业软件相似性鉴定。双指纹方法能够有效发现部分表层改写和高相似提交，但对于大规模重构、多语言混合项目、模板化代码复用以及第三方依赖高度重合等场景，仍可能出现误报或漏报。因此，系统输出应作为审核辅助依据，与人工复核、业务规则和法律审查共同构成最终判断链条。

后续研究可从三个方面继续扩展。首先，可引入更细粒度的代码结构特征，如函数级摘要、调用关系特征或抽象语法树特征，以提升对深层改写样本的识别能力。其次，可在更大规模、多项目和跨组织数据集上进行长期评估，检验阈值规则在不同业务分布下的稳定性。最后，可探索动态阈值学习和审核反馈闭环，使系统根据历史复核结果自动调整分流策略，在保证风险控制能力的同时进一步降低人工审核成本。

参考文献

[1] DI LUNA G A, et al. The Software Heritage Graph Dataset: Public Software Development Under One Roof[C]//Proceedings of the IEEE/ACM 42nd International Conference on Software Engineering. New York: ACM, 2020: 138–148.

[2] NOVAK M, JOY M, KERMEK D. Source-Code Similarity Detection and Detection Tools Used in Academia: A Systematic Review[J]. ACM Transactions on Computing Education, 2019, 19(3): 1–37.

[3] SCHLEIMER S, WILKERSON D S, AIKEN A. Winnowing: Local Algorithms for Document Fingerprinting[C]//Proceedings of the 2003 ACM SIGMOD International Conference on Management of Data. New York: ACM, 2003: 76–85.

[4] NAKAMOTO S. Bitcoin: A Peer-to-Peer Electronic Cash System[EB/OL]. 2008.

[5] 中华人民共和国司法部. SF/T 0158–2023 软件相似性鉴定技术规范 [S]. 北京: 中国标准出版社, 2023.